


Karar Ağaçları (Decision Tree)

Verileri bir dizi kurala göre bölerek sınıflandırma veya regresyon problemleri için kullanılan bir **denetimli öğrenme** (supervised learning) algoritmasıdır. İf-else yapısına benzeyen çalışma mantığı sayesinde insanlar tarafından kolayca anlaşılabilir.



Aklımıza; neden kök “*ilgili kişi atletik mi*” sorusu oluyor da diğerleri olmuyor?, evet ise neden “*spor yapıyor mu*” değil de “*yağ oranı %20’nin altında mı*” ya bakıyoruz? gibi sorular gelebilir. İşte bunun matematiksel nedenine bakacağız.

Cart ve ID3 Farkı

- **ID3 (Iterative Dichotomiser 3):** Sadece **kategorik veriler** için kullanılır. Her bölünme adımında Entropy ve **Bilgi Kazancı (Information Gain)** kullanır. **Çoklu dallara ayrılabilir (çoklu dallanma).**
- **CART (Classification and Regression Trees):** Hem **sınıflandırma** hem de **regresyon** problemleri için kullanılır. Sınıflandırma için **Gini Impurity**, regresyon için ise **ortalama kare hatası (MSE)** gibi ölçütler kullanır. Sadece ikili bölünmeler (binary splits) yapar, yani her düğümü ikiye ayırır.

CART, daha esnek olması ve hem sınıflandırma hem de regresyon için kullanılabilmesi nedeniyle günümüzde daha yaygın olarak tercih edilir.


Karar Ağacında Amaç

Karar ağacının temel amacı, bir veri setini en iyi şekilde bölerek **saf** (pure) düğümler oluşturmaktır. **Saf düğümler, mümkün olduğunca aynı sınıfa ait verileri içeren düğümlerdir.** Bu, her bir bölünme adımında veri setini en iyi ayıran özelliği bulmakla yapılır. Bu işlem, genellikle **Entropy** ve **Gini Impurity** gibi ölçütlerle yapılır.

Yani veri setini öyle bir bölmeye çalışıyoruz ki, her bölme sonucu oluşan alt kümeler mümkün olduğunca homojen (**saf**) olsun.

ID	GPA	Interview Score	Approval (Y)	
1	<3.0	Düşük	Red	bu veride ;
2	<3.0	Yüksek	Onay	
3	<3.0	Yüksek	Onay	GPA→ortalama;
4	>3.0	Düşük	Red	
5	>3.0	Yüksek	Onay	Interview Score→mülakat skoru
6	>3.0	Normal	Onay	
7	<3.0	Normal	Red	Approval→ mülakat sonucu


Table 1: Karar ağacı için örnek veri seti



*Buna baktığımız zaman GPA'sı 3'den küçük olan 2 kişi "yes" 2 kişi "no" almış mülakat sonucunu.

*3'den büyük olanlarda ise 2 "yes" 1 tane de "no" var.

!!!Ama ben işte bu kök ile başlamak zorunda değilim demi. "Interview Score" ile de başlayabilirim. İnceleyelim onu da...



*Buna baktığımız zaman “Interview Score”u **yüksek** olanların hepsi “yes” almış.

*Ama **yüksek olmayanlarda** ise 1 tane “yes” 3 tane de “no” var.

Şimdi bu ikisi için hangisi kök daha iyi olur dersek → “Interview Score”. Çünkü **daha homojen**.

-**Yeni biri geldiğini düşün. Interview Score’u yüksek ise zaten direkmen mülakatı geçiyor değil mi. Ama GPA’sı da 3’den büyükse veya küçükse her zaman da onay alamıyor değil mi.**

Tabi biz bu durumu gözümüzle gördük bunun 2 tane matematik hesaplaması vardır.

Entropy ve Gini Impurity

Bu iki ölçüt, bir veri setinin ne kadar **karışık** olduğunu (saf olmaktan ne kadar uzak olduğunu) belirlemek için kullanılır. Amacımız, her bölünme adımında bu değerleri **minimuma** indirmektir.

!!!!!!Bir düğümün Entropy veya Gini değeri 0’a ne kadar yakınsa, o düğümdeki veriler o kadar homojendir (aynı sınıfa aittir). Bu da modelin doğru tahminler yapması için ideal bir durumdur.

Entropy

Entropy, bir veri setindeki belirsizliğin veya rastgeleliğin bir ölçüsüdür. Değer ne kadar yüksekse, karışıklık da o kadar fazladır. Mükemmel bir şekilde saf bir düğümün Entropy değeri **0**’dır. En karışık durum için ise Entropy değeri **1**’e yakındır.

-Yani bir veri setindeki duzensizliği olcen bir metriktir. **Düşük entropy = daha saf küme.**

C=Sınıf Sayısı, p_i = sınıf i’nin olasılığı

$$H(S) = - \sum_{i=1}^C p_i \log_2(p_i)$$

Example; 7 örneğimizde 4 yes, 3 no : →→→

$$H = -\frac{4}{7} \log_2 \frac{4}{7} - \frac{3}{7} \log_2 \frac{3}{7} \approx 0.985$$

Gini Impurity

Bir veri setinden rastgele seçilen bir örneğin **yanlış sınıflandırılma olasılığının** bir ölçüsüdür. Gini değeri 0'a ne kadar yakınsa, veri setindeki saflık o kadar yüksektir.

$$G(S) = 1 - (p_{\text{Yes}}^2 + p_{\text{No}}^2)$$

Example; 4 yes 3 no:

$$G = 1 - \left(\frac{4}{7}\right)^2 - \left(\frac{3}{7}\right)^2 \approx 0.4898$$

Bizim split adaylarımız;

Split 1- Interview Score = yüksek mi?

Split 2- GPA >3 mu?

Interview Score = yüksek

***Yes grubu:** (ID 2,3,5) → Hepsi Onay → **Entropy = 0** (karmaşıklık Yok)

***No grubu:** (ID 1,4,6,7): 1 Onay, 3 Red;

$$H = -\frac{1}{4} \log_2 \frac{1}{4} - \frac{3}{4} \log_2 \frac{3}{4} \approx 0.811$$

–Bilgi kazancı;

$$\text{Gain} = 0.985 - \left(\frac{3}{7} \times 0 + \frac{4}{7} \times 0.811 \right) \approx 0.985 - 0.464 = 0.521$$

Bütün ağacınkinden, her değerin olasılığı ile entropy'si çarpılıp, çıkarılıyor.

GPA>3 için

– Yes grubu: (ID 4,5,6): 2 Onay, 1 Red ;

$$H = -\frac{2}{3} \log_2 \frac{2}{3} - \frac{1}{3} \log_2 \frac{1}{3} \approx 0.918$$

– No grubu: (ID 1,2,3,7): 2 Onay, 2 Red;


$$H = -0.5 \log_2 0.5 - 0.5 \log_2 0.5 = 1$$

-Bilgi Kazancı;

$$\text{Gain} = 0.985 - \left(\frac{3}{7} \times 0.918 + \frac{4}{7} \times 1 \right) \approx 0.985 - (0.393 + 0.571) = 0.021$$

Sonuç;

En iyi split için **Interview Score (0.521) > GPA>3 (0.021)** olduğu için **Interview Score** seçilir.



şuna benzer olacak ağaç.

Pruning (Budama)

Budama (pruning) bir karar ağacını **aşırı öğrenme (overfitting)** probleminden korumak için kullanılan bir tekniktir.

Bir karar ağacını, bir meyve ağacı gibi düşünebilirsin. Meyve ağacı ne kadar çok dal verirse, o kadar çok meyve taşıyabilir. Ancak, çok fazla dal ve yaprak, ağacın enerjisini tüketebilir ve ana gövdeyi zayıflatabilir. Tıpkı bunun gibi, bir karar ağacı da eğitim verilerini ezberleyecek kadar "derin" ve "karmaşık" hale gelebilir.

Eğitim verileri üzerinde %100 doğrulukla çalışan bir modelin mükemmel olduğunu düşünebilirsin. Ama durum genellikle böyle değildir. Çünkü model, verideki ufak tefek gürültüyü ve rastgele varyasyonu bile öğrenir. Bu da, yeni ve daha önce görmediği verilerle karşılaştığında kötü performans göstermesine neden olur. Bu duruma **aşırı öğrenme** denir.

Budama, bu gereksiz ve karmaşık dalları keserek ağacı daha basit, daha genellenebilir ve yeni verilere daha iyi uyum sağlayan bir hale getirir.



Figure 5: Budama Öncesi Karar Ağacı




Figure 6: Budama Sonrası Karar Ağacı

!Çok dallanıp budaklanırsa işte sanki sadece train setimize göre ağacı oluşturuyomuş gibi olur, test setimizi hiç düşünmüyormuşuz gibi olur.

Karar Ağacı Regresyonu (Decision Tree Regressor) ve Varyans Azaltımı

Bazen tahmin etmemiz gereken şey bir sınıf değil, sürekli bir sayıdır. Örneğin, bir evin fiyatı, bir kişinin maaşı veya bir bitkinin boyu. Bu tür problemlere **regresyon problemleri** denir. İşte bu noktada **Karar Ağacı Regresyonu** devreye girer.

Karar Ağacı Sınıflandırma vs. Karar Ağacı Regresyonu

- **Sınıflandırma Ağacı:** Veriyi bölerek her yaprak düğümünde tek bir sınıfa ait verileri toplamayı amaçlar. Bu işlem için **Entropy** ve **Gini Impurity** gibi ölçütleri kullanarak saflığı (homojenliği) artırmaya çalışır.
- **Regresyon Ağacı:** Veriyi bölerek her yaprak düğümünde birbirine yakın sayısal değerleri toplamayı amaçlar. Bu işlem için **varyansı** (dağılımı) azaltmaya çalışır.

Burda işte **MSE** ya da **Varyans Azaltımı (Variance Reduction)** kullanılarak hangi split'in daha iyi olduğu anlamaya çalışılır.

Varyans Azaltımı Nedir?

Bir veri setindeki **varyans**, verilerin ortalamadan ne kadar uzaklaştığını, yani ne kadar dağınık olduğunu gösterir. Regresyon ağacının temel amacı, her bir bölünme (split) adımıyla bu dağılımı en aza indirmektir.

Şöyle düşünelim: Elinde çeşitli yaş gruplarından insanların boyuyla ilgili bir veri seti var. Regresyon ağacı, ilk olarak bu veriyi "yaş"a göre ayırır. Örneğin:

- Yaş < 10 olanlar
- Yaş >= 10 olanlar

Bunu yaparken, "Yaş < 10" grubundaki boy verilerinin kendi içlerindeki **dağılımını** (varyansını) ve "Yaş >= 10" grubundaki boy verilerinin kendi içlerindeki **dağılımını** en aza indiren bölünmeyi seçer. Her bölünme, o alt kümenin daha homojen (birbirine daha benzer değerlerden oluşan) hale gelmesini sağlar.

Example;

Karar ağaçları yalnızca kategorik değil, sürekli değişkenlerle de çalışabilir. Örneğin GPA gibi sürekli bir değişken ile karar ağacı bölmesi yapmak için tüm olası eşikler denenir.

ID	GPA	Burs Miktarı (bin TL)
1	2.5	10
2	2.7	12
3	3.0	18
4	3.2	22
5	3.5	30
6	3.7	35
7	4.0	40

Table 2: Decision Tree Regressor için örnek veri seti

Olası Split Eşikleri

$$\frac{2.5 + 2.7}{2} = 2.6, \quad \frac{2.7 + 3.0}{2} = 2.85, \quad \frac{3.0 + 3.2}{2} = 3.1, \quad \frac{3.2 + 3.5}{2} = 3.35, \quad \frac{3.5 + 3.7}{2} = 3.6, \quad \frac{3.7 + 4.0}{2} = 3.85$$

Her eşik için varyans azaltımı hesaplanır ve en iyi split noktası seçilir.

Varyans Hesaplama (Örnek olarak GPA < 3.1)

Sol Grup için; {burs miktarları: 10, 12, 18}, Ortalama: 13.33,

Varyans;

$$\frac{(10 - 13.33)^2 + (12 - 13.33)^2 + (18 - 13.33)^2}{3} = \frac{(11.11) + (1.77) + (21.78)}{3} \approx 11.55$$

Sağ Grup İçin; {burs miktarları: 22, 30, 35, 40} Ortalama: 31.75

Varyans;

$$\frac{(22 - 31.75)^2 + (30 - 31.75)^2 + (35 - 31.75)^2 + (40 - 31.75)^2}{4} = 44.19$$

Kök Varyans;

Tüm veri için ortalama: 23.86

Tüm veri için varyans;

$$\frac{(10 - 23.86)^2 + (12 - 23.86)^2 + (18 - 23.86)^2 + (22 - 23.86)^2 + (30 - 23.86)^2 + (35 - 23.86)^2 + (40 - 23.86)^2}{7} \approx 124.83$$

Varyans Azaltımı

Ağırlıklı Varyans; $\frac{3}{7} \times 11.55 + \frac{4}{7} \times 44.19 \approx 4.95 + 25.24 = 30.19$

Varyans Azaltımı; $124.83 - 30.19 = 94.64$

Diğer Splitler İçin;

Karar ağacı tüm eşikleri dener ve varyans azaltımını hesaplar. Yukarıda detaylıca hesapladığımız GPA<3.1 spliti yaklaşık **94.64** çıktı. Diğer olası eşikler için;

Eşik	Varyans Azaltımı	Açıklama
2.6	37.5	Çok küçük bölme; sağ grup geniş.
2.85	68.2	İyi ama optimum değil.
3.1	94.6	En yüksek varyans azaltımı.
3.35	80.3	Orta.
3.6	72.1	Daha zayıf.
3.85	60.4	En sağdaki değerler ayrışıyor ama varyans yüksek.

Görüldüğü gibi, **3.1** eşik en yüksek varyans azaltımını sağlamaktadır. Bu yüzden karar ağacı bu split'i seçmiştir. Split seçimi sırasında amaç, veri setini ikiye ayırırken **en homojen grupları** oluşturmaktır; varyans azaltımı bu homojenliği ölçer.

Decision Tree Regressor: Tahmin Mantığı

Test örneğini yaprak düğüme ulaştırdığında, bu yapraktaki hedef değerlerin ortalamasını döner.

Example; Bir test öğrencisi için GPA=3.3,

Bu örnek, örneğin GPA > 3.1 olan dala gider. Bu dalda değerler→{22,30,35,40}

Bu yapraktaki ortalama→ $(22 + 30 + 35 + 40) / 4 = 31.75$

Dolayısı ile tahminin sonucu **31.75** olur.