

Ensemble Öğrenme Yöntemleri:

Bagging & Boosting

Ensemble öğrenme, en basit tabirle, tek bir modelin tahminlerinden ziyade **birden fazla modelin tahminlerini bir araya getirerek daha doğru ve kararlı sonuçlar elde etmeyi amaçlayan bir makine öğrenmesi tekniğidir**. Bu yöntem, "birlikten kuvvet doğar" mantığına dayanır.

Tek başına çok iyi olmayan modeller bile bir araya geldiğinde, her birinin farklı hatalar yaptığı ve bu hataların birbirini telafi ettiği bir sistem oluşur. Bu, genel performansı artırırken, aşırı öğrenme (overfitting) riskini de azaltır.

Bagging (Torbalama)

Aynı veya farklı türden birden fazla base learner (temel model) kullanarak veri setinin farklı alt örnekleri üzerinde bu modelleri eğitir.

–Bu yöntemde, aynı türden modeller **paralel** olarak eğitilir. (Logistic, Karar Ağaçları ...) Bu sayede eğitim süreci hızlandırılır.

–Önce, ana veri setinden rastgele örneklemeler (bootstrap) alınarak birden fazla alt veri seti oluşturulur.


–Daha sonra, her bir alt veri seti üzerinde birer model eğitilir.

–Son tahmin, tüm modellerin oylarının veya ortalamasının alınması ile belirlenir.

–En popüler bagging algoritması **Rastgele Orman (Random Forest)**'dir. Bu algoritma, birçok karar ağacını birleştirerek çalışır ve her bir ağacın rastgele seçilen özelliklerle eğitilmesiyle daha da çeşitlilik kazanır.

*Sınıflandırma problemlerinde → **Çoğunluk oylaması (Majority Voting)**

*Regresyon Problemlerinde → **Ortalama Alma (Average) yapısı**.



- **Random Forest:** Bagging yönteminin en bilinen örneklerinden biridir ve temel olarak birden fazla karar ağacını bir araya getirir.

Boosting

Zayıf öğreniciler (**weak learners**) olarak adlandırılan modelleri ardışık olarak eğitir. Her model, önceki modelin başarısız olduğu veri örneklerine odaklanır. Böylece hatalar kademeli olarak azaltılır.


*Bu yöntemde, modeller **sıralı** bir şekilde eğitilir.

*Her yeni model, bir önceki modelin yanlış yaptığı tahminleri düzeltmeye odaklanır.

*Yani, bir modelin hataları, bir sonraki modelin eğitilmesinde ağırlıklı olarak kullanılır.

*Bu yaklaşım, zayıf öğrenicileri (weak learners) birleştirerek güçlü bir öğrenici (strong learner) oluşturur.

*Örnek algoritmalar arasında **AdaBoost**, **Gradient Boosting Machines (GBM)** ve **XGBoost** gibi çok etkili ve sıkça kullanılan algoritmalar bulunur.



Boosting'in en önemli özelliği, tüm modellerin **ardışık olarak eğitilmesidir**. Her yeni model, önceki modelin hatalarından ders çıkarır.

Figure 1: Boosting yönteminin hata katsayıları ve güçlü model ile detaylı görselleştirilmesi

Bir Örnekle Açıklama:

Bir öğrencinin 100 soruluk bir sınava girdiğini düşün.

- **1. Tur (İlk Model):** Öğrenci sınavı çözer. 100 sorudan 70'ini doğru, 30'unu yanlış yapar.
- **2. Tur (İkinci Model):** Şimdi, sadece yanlış yaptığı o **30 soruya** odaklanır ve bu sorular üzerinde ekstra çalışır. Bu 30 soruyu tekrar çözerek bazılarını doğru yapar.
- **3. Tur (Üçüncü Model):** İkinci turda bile yanlış yaptığı sorular varsa, bu sorulara daha da fazla odaklanarak üçüncü kez çalışır.

Boosting de tam olarak bu mantıkla çalışır: yanlış yapılan her tahmin, bir sonraki model için **ekstra bir öğrenme fırsatı** haline gelir. Bu sıralı ve hedef odaklı süreç sayesinde, her yeni model bir öncekini tamamlayarak, tek bir modelin ulaşamayacağı bir doğruluk seviyesine ulaşır.

4 Bagging ve Boosting Karşılaştırması

- **Eğitim Şekli:** Bagging paralel çalışırken, Boosting ardışık çalışır.
- **Hedef:** Bagging varyansı azaltmayı hedefler; Boosting ise bias'ı azaltır.
- **Öğrenici Türü:** Bagging, genellikle güçlü öğreniciler kullanır; Boosting ise zayıf öğrenicileri güçlü hale getirir.

in Bagging;

Varyans, bir modelin farklı eğitim veri setlerinde ne kadar farklı sonuçlar ürettiğini gösterir. Yüksek varyans, modelin yeni verilere karşı çok hassas olduğu ve **aşırı öğrenme (overfitting)** eğilimi gösterdiği anlamına gelir. **farklı veri setlerindeki ufak dalgalanmalardan daha az etkilenen bir model** elde ederiz.

in Boosting;

Bias (yanlılık), bir modelin gerçek ilişkiyi öğrenmekte yetersiz kalması, yani **yetersiz öğrenme (underfitting)** eğilimi göstermesidir. Yüksek bias'lı bir model, verideki karmaşıklığı yakalayamaz ve her zaman benzer basit hataları yapar.

Bir dizi "zayıf" model, birleşerek veri setindeki tüm karmaşıklığı ve ilişkileri öğrenebilen daha güçlü ve karmaşık bir model oluşturur.