

Naive Bayes Teoremi

Koşullu olasılık

Bir olayın, başka bir olayın gerçekleştiği bilgisi altında gerçekleşme olasılığıdır..

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Bu formül, "B olayı gerçekleştiğinde A olayının olasılığı nedir?" sorusunu yanıtlar

Bayes Teoremi

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

-**P(A|B)**: Gözlem B verildiğinde, A'nın olasılığı (posterior)

-**P(B|A)**: A verildiğinde B'nin olasılığı (likelihood)

Naive Bayes, bir veri noktasının hangi kategoriye ait olduğunu tahmin etmek için **olasılık** kullanır. Temelinde Bayes Teoremi yatar

Teorem, bir olayın gerçekleşme olasılığını, o olayla ilgili diğer olayların gerçekleşme olasılığına dayanarak hesaplar.

$$P(y|x_1, x_2, \dots, x_n) = \frac{P(y) \cdot P(x_1|y) \cdot P(x_2|y) \cdots P(x_n|y)}{P(x_1, x_2, \dots, x_n)}$$

Naive Bayes'in "naive" olarak adlandırılmasının nedeni, özelliklerin birbirinden bağımsız olduğu varsayımdır. Yani:

$$P(x_1, x_2, \dots, x_n|y) = P(x_1|y) \cdot P(x_2|y) \cdots P(x_n|y)$$

Basitçe, şöyle düşünebilirsin:

"Bir kişinin grip olma olasılığı nedir, eğer o kişi hapşıırma ve öksürme belirtileri gösteriyorsa?"

Naive Bayes, bu soruyu çözmek için şunu yapar:

1. **Önceki Bilgi (Prior Probability):** Toplumda genel olarak grip olma olasılığı nedir?
2. **Kanıt (Likelihood):** Grip olan kişilerin ne kadarı hapşıırır ve öksürür?
3. **Çıktı (Posterior Probability):** Hem hapşııran hem de öksüren bir kişinin grip olma olasılığı nedir?

Naive Bayes Ne İçin Kullanılır?

- **Metin Sınıflandırma:** Spam e-posta filtreleri, makalelerin konusunu belirleme (spor, politika vb.).
- **Duygu Analizi:** Bir metnin olumlu mu, olumsuz mu olduğunu belirleme.
- **Hastalık Tahmini:** Belirtilere göre hastalığı tahmin etme.

Example: E-Posta Sınıflandırma → Spam / Ham

Amaç, gelen bir e-postanın spam mi yoksa normal (ham) mı olduğunu belirlemektir. Veri kümesinde yalnızca iki özellik (feature) bulunmaktadır: **Free ve Win**, yani bu kelimelerin e-posta metninde bulunup bulunmadığı.

Free	Win	Label (Sınıf)
Yes	Yes	Spam
Yes	No	Spam
No	Yes	Ham
Yes	Yes	Spam
No	No	Ham

Amaç: Free = Yes, Win = No olan yeni bir e-postanın sınıfını tahmin etmek

Step 1-Sınıf olasılıklarını hesapla (Prior)

$$P(\text{Spam}) = \frac{3}{5}, \quad P(\text{Ham}) = \frac{2}{5}$$

Step 2- Koşullu olasılıkları hesapla (Likelihood)

- $P(\text{Free}=\text{Yes}|\text{Spam}) = \frac{3}{3} = 1.0$
- $P(\text{Free}=\text{Yes}|\text{Ham}) = \frac{0}{2} = 0.0$
- $P(\text{Win}=\text{No}|\text{Ham}) = \frac{1}{2}$

Step 3: Tahmin Edilecek Olasılıkları Hesapla

Yeni bir e-posta geldi: Free = Yes, Win = No →

Spam olma olasılığı ;

$$P(\text{Spam}|\text{Free}=\text{Yes}, \text{Win}=\text{No}) \propto P(\text{Spam}) \cdot P(\text{Free}=\text{Yes}|\text{Spam}) \cdot P(\text{Win}=\text{No}|\text{Spam}) \\ = (3/5) * 1 * (1/3) = 1/5$$

Ham olma olasılığı;

$$P(\text{Ham}|\text{Free}=\text{Yes}, \text{Win}=\text{No}) \rightarrow (2/5) * 0 * (1/2) = 0$$

Sonuç;

$P(\text{Spam}|\text{Free}=\text{Yes}, \text{Win}=\text{No}) > P(\text{Ham}|\text{Free}=\text{Yes}, \text{Win}=\text{No}) \rightarrow$ Spam olarak sınıflandırılır.

Naive Bayes Varyantları: Bernoulli, Multinomial ve Gaussian

Bernoulli Naive Bayes

Bağımsız değişkenlerin (features) yalnızca iki farklı değer alabildiği durumlar için uygundur. Bu iki değer genellikle **0-1, Evet-Hayır, Var-Yok, Başarılı-Başarısız** gibi ikili (binary) durumlardır. *Özellikler Bernoulli dağılımını izler.*

Kullanım Alanı:

Tıklanma tahmini, e-posta açılıp açılmama, kullanıcı davranışları ("örneğin bir özelliği kullanmış mı?)

Free Offer	Clicked	Purchased
Yes	No	No
Yes	Yes	Yes
No	No	Yes
Yes	No	No
No	Yes	Yes

Yandaki örnekte **her bir özellik** yalnızca **Yes/No (1/0)** biçimindedir, bu nedenle Bernoulli Naive Bayes kullanılabilir

Multinomial Naive Bayes

Özellikle metin verisi (text data) ile çalışmak için uygundur. Bu model, bir özelliğin (örneğin bir kelimenin) bir örnekte kaç defa geçtiğine (frekansına) göre çalışır. Bu nedenle, **en çok kullanılan doğal dil işleme (NLP) görevlerinde tercih edilir.**

Veri Türü: Sayma (count-based), kelime frekansı

Kullanım Alanı: E-posta spam tespiti, haber kategorilendirme, **duygu analizi**

Example; Aşağıdaki metinlerin **spam** olup olmadığını belirlemek istiyoruz.

- E-posta1 : “Win 1000\$ now!” → Spam
- E-posta 2: “Hi Karaduman, how was meeting yesterday?” → Ham

Özellik Matrisi (Bag of Words)

	win	now	meeting	yesterday
Spam	1	1	0	0
Ham	0	0	1	1

Burda mesela now kelimesi cümlede bir daha veya daha fazla olsaydı o kadar yazcaktı. 5 defa geçiyorsa 5 yazcaktı. 1-0 gibi var veya yok anlamında değil kaç defa geçiyorsa onu yazacak.

Gaussian Naive Bayes

Özelliklerin **surekli sayısal değerler aldığı durumlarda** kullanılır. Eğer veriniz ortalama etrafında simetrik bir dağılım (çan eğrisi– normal dağılım) gösteriyorsa bu algoritma uygundur. Özelliklerin Gaussian (normal) dağılım gösterdiği varsayılır.

Veri Türü: Sürekli (Continuous)

Kullanım Alanı: Yas, boy, kilo gibi fiziksel ölçümlerle yapılan sınıflandırmalar, medikal veriler.

Example;

Age	Weight	Height	Obese?
25	80	170	Yes
30	90	165	Yes
22	55	178	No
28	60	180	No

Bu verideki **yaş, kilo ve boy** değişkenleri **surekli (continuous) olduğundan Gaussian Naive Bayes** kullanılabilir. Her bir özellik için, sınıfa göre ayrı ayrı ortalama (μ) ve standart sapma (σ) hesaplanır. Olasılıklar aşağıdaki normal dağılım fonksiyonu ile hesaplanır

$$P(x_i|y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

Hangi Varyantı Ne Zaman Kullanmalıyım?

- Özellikler **0/1** ise $\Rightarrow$ **Bernoulli**
- Özellikler **kelime sayısı** veya **frekans ise** $\Rightarrow$ **Multinomial**
- Özellikler **sürekli sayı** ise ve normal dağılıma yakın dağılımlar (örneğin yas, boy, gelir) $\Rightarrow$ **Gaussian**
- Gaussian için özellikler sürekli ama normal dağılıma uymuyorsa, transformasyon fonksiyonları ile normal dağılıma yakınlştırılabilir.